

Relatório Técnico: Modelo Preditivo para o Índice IBOVESPA

1. Introdução e Objetivo do Projeto

O objetivo deste projeto foi desenvolver um modelo preditivo para prever a tendência de fechamento (alta ou baixa) do índice IBOVESPA para o dia seguinte. Este modelo servirá como um insumo para dashboards internos, auxiliando analistas quantitativos na tomada de decisão.

Para isso, foi utilizada a base de dados histórica do IBOVESPA, com granularidade diária, abrangendo um período extenso para garantir a robustez e a capacidade de generalização do modelo.

- **2. Exploração, Limpeza e Padronização dos Dados**
- A primeira etapa, detalhada no notebook `01_exploracao_e_limpeza.ipynb`, consistiu no tratamento dos dados brutos. O processo incluiu:
- **Carregamento e Análise Inicial:** O conjunto de dados foi carregado e verificado quanto à sua estrutura, tipos de dados e presença de valores ausentes.
- **Limpeza e Conversão:**
 - As colunas numéricas (Último, Abertura, etc.) foram convertidas de string para o tipo float.
 - A coluna Vol. (Volume) foi padronizada para um valor numérico único, tratando as abreviações "B" (bilhões) e "M" (milhões).
 - A coluna Data foi convertida para o formato `datetime`, essencial para a análise de séries temporais.
- **Ordenação e Exportação:** O dataframe foi ordenado cronologicamente e salvo em um novo arquivo (`01_limpeza_e_padronizacao.csv`) para as etapas seguintes.

Out[11]:

	Último	Abertura	Máxima	Mínima	Vol.	Var%
Data						
2005-01-17	24.515	24.924	25.022	24.515	7.506000e+07	-1.64
2005-01-18	24.089	24.515	24.515	24.019	1.794200e+08	-1.74
2005-01-19	24.271	24.091	24.465	24.091	1.131100e+08	0.76
2005-01-20	23.610	24.271	24.271	23.534	1.820600e+08	-2.72
2005-01-21	23.818	23.618	24.006	23.609	9.740000e+07	0.88
...	...	...	...	...	...	...
2025-03-19	132.508	131.476	132.984	131.451	1.220000e+10	0.79
2025-03-20	131.955	132.505	132.713	131.813	1.419000e+10	-0.42
2025-03-21	132.345	132.005	132.588	131.776	1.419000e+10	0.30
2025-03-24	131.321	132.344	132.424	130.992	8.300000e+09	-0.77
2025-03-25	132.068	131.327	133.471	131.325	9.240000e+09	0.57

5000 rows × 6 columns

3. Análise Exploratória dos Dados (EDA)

No notebook `02.Análise_exploratória_dos_dados.ipynb`, foi realizada uma análise detalhada para extrair insights e entender o comportamento do IBOVESPA ao longo do tempo. Os principais pontos observados foram:






Gráfico da Série Histórica

- **Observação:** O gráfico mostra a evolução do IBOVESPA, destacando um pico em 2008, seguido por uma queda abrupta; um período de volatilidade até 2016; uma nova tendência de alta até 2020; um *crash* no início da pandemia e uma posterior consolidação entre 100.000 e 130.000 pontos.
- **Insight:** A história do índice é marcada por ciclos e eventos macroeconômicos. Um modelo preditivo precisa ser treinado com um longo histórico para aprender com esses diferentes "regimes" de mercado e não ser enviesado por um único período.




Boxplot do Preço de Fechamento

- **Observação:** O Boxplot evidencia uma distribuição assimétrica, com a mediana (linha central) localizada em uma faixa de preço mais baixa e uma longa cauda superior com múltiplos *outliers* (pontos).
- **Insight:** Os picos históricos de preço são eventos estatisticamente raros. O modelo será treinado majoritariamente com dados de períodos de menor cotação, o que pode representar um desafio para prever novas máximas históricas.



Análise de Densidade: Gráfico de Violino do Preço de Fechamento

- **Observação:** O gráfico exibe uma clara distribuição **bimodal**, com dois "picos" de densidade: um maior e mais largo em torno de 60.000 pontos e outro menor, em um patamar mais elevado, próximo a 115.000 pontos. A forma geral é assimétrica, com uma cauda direita mais longa.
- **Insight:** A bimodalidade é a característica mais relevante. Ela revela que o IBOVESPA não se concentra em um único valor médio, mas sim operou historicamente em **dois "regimes" ou "patamares" de preço principais** onde passou a maior parte do tempo. As faixas de preço mais estreitas no gráfico foram apenas zonas de transição entre esses dois patamares.




Análise da Série Histórica de Volume

- **Observação:** O gráfico de volume, em escala logarítmica, revela uma **quebra estrutural massiva em 2008**, com o patamar de negociação caindo drasticamente. Este nível baixo e estável perdurou por quase uma década, até que uma lenta recuperação se iniciou por volta de 2018. No final da série, observa-se um **pico anômalo e extremo** de volume.
- **Insight:** A crise de 2008 não afetou apenas o preço, mas **alterou fundamentalmente a liquidez** do mercado, que levou anos para se recuperar. O pico anômalo no final da série é um ponto de atenção crítico que pode ser um evento extraordinário ou um erro nos dados, e precisa ser investigado, pois pode distorcer a análise do modelo.



Análise de Tendência com Médias Móveis


- **Observação:** O preço do IBOVESPA permanece consistentemente **acima** das médias móveis em longos períodos de alta (ex: 2016-2018) e cruza para **baixo** de todas elas em momentos de reversão, como na crise de 2008. Frequentemente, em uma tendência, o preço recua até tocar uma das médias antes de continuar seu movimento.
- **Insight:** A posição do preço em relação às médias móveis é um indicador claro da tendência principal do mercado (*bull vs. bear market*). Além disso, as próprias médias atuam como **suportes e resistências dinâmicos**, fornecendo níveis de preço relevantes onde a força do movimento é testada.



Análise da Matriz de Correlação (Heatmap)

- **Observação:** O heatmap exibe uma correlação positiva perfeita (valor 1.0) entre as variáveis de preço (Último, Abertura, Máxima, Mínima). A variável Ano também mostra uma forte correlação positiva (0.88) com os preços, enquanto features sazonais como Mes e Dia_da_semana têm correlação próxima de zero.
- **Insight:** A correlação perfeita entre os preços indica redundância, o que pode causar multicolinearidade em alguns modelos. A correlação com Ano simplesmente captura a tendência de alta de longo prazo do IBOVESPA. A ausência de correlação linear com datas (mês, dia) sugere que os padrões sazonais, se existirem, são mais complexos e não-lineares.


A maioria dos dias tem variação próxima de zero, mas eventos extremos são mais comuns do que o esperado.



Análise da Distribuição dos Retornos Diários


- **Observação:** O histograma mostra uma altíssima concentração de retornos diários na faixa entre -1% e +1%. No entanto, o gráfico também registra a ocorrência de variações extremas, embora raras, que chegam a -10% e +10% em um único dia.
- **Insight:** Esta distribuição revela o fenômeno das "**caudas gordas**" (leptocurtose), que é característico dos mercados financeiros. Isso significa que, embora o comportamento mais comum seja de pequenas variações diárias, a probabilidade de ocorrer um evento extremo (uma grande alta ou uma grande queda) é significativamente maior do que uma distribuição normal sugeriria.

Cada caixa representa a variação do preço no ano. A linha pontilhada mostra a evolução da mediana anual.



Análise da Distribuição Anual (Boxplot por Ano)


- **Observação:** O gráfico mostra que até 2018, o IBOVESPA negociava majoritariamente abaixo dos 80.000 pontos, passando a operar consistentemente acima dos 100.000 a partir de 2019. O tamanho das caixas e dos "bigodes" é visivelmente maior em anos como 2008 and 2020.
- **Insight:** A mudança de patamar indica uma **reprecificação estrutural** do mercado. O tamanho de cada boxplot anual funciona como um indicador visual da **volatilidade** daquele período, confirmando que 2008 e 2020 foram anos de instabilidade extrema.



Análise Sazonal: Efeito do Dia da Semana

- **Observação:** A análise comparativa entre os dias da semana mostra que a média de preço é praticamente idêntica, as distribuições nos boxplots são muito similares e a correlação linear com o preço de fechamento é efetivamente zero.
- **Insight:** Com base nos dados históricos, **não existe um "efeito dia da semana"** que seja estatisticamente relevante ou previsível. Isso indica que a variável "dia da semana" provavelmente terá baixo ou nenhum poder preditivo para o modelo.

Análise Sazonal: Ausência de um 'Efeito Mês' Forte e Consistente



Análise Sazonal: Efeito do Mês

- **Observação:** A análise comparativa mostra que as médias de preço entre os meses são muito próximas, as distribuições nos boxplots são similares e a correlação linear com o preço de fechamento é efetivamente zero (0.0039).
- **Insight:** Semelhante à análise semanal, **não há um efeito sazonal mensal forte e confiável** no histórico completo dos dados. Nenhum mês específico se destaca como um preditor consistente de alta ou baixa para o IBOVESPA

Conclusão da Análise Exploratória

A análise exploratória dos dados históricos do IBOVESPA revelou a natureza complexa e multifacetada do mercado financeiro brasileiro. A jornada do índice não é linear, mas sim uma série de ciclos, tendências e quebras estruturais, profundamente influenciada por eventos macroeconômicos, como a crise de 2008 e a pandemia de 2020.

Descobrimos que o IBOVESPA não opera em torno de uma única média, mas sim em **diferentes "regimes" ou "patamares" de preço e volume**, o que valida a necessidade de modelos que consigam se adaptar a diferentes contextos de mercado. A análise de distribuição dos retornos confirmou o fenômeno das **"caudas gordas"**: o comportamento mais comum é de pequenas variações diárias, mas a probabilidade de um evento extremo é maior do que se poderia esperar, tornando a gestão de risco um fator crucial.

A investigação de padrões sazonais demonstrou que **não há um "efeito calendário" simples e direto**; os dias da semana ou meses do ano, isoladamente, não possuem poder preditivo relevante.

Com base nesses insights, a etapa de modelagem confirmou que, apesar da aparente aleatoriedade, existem padrões que podem ser capturados. A análise foi fundamental, revelando que o **comportamento recente do preço (lags) e do volume, juntamente com a distância para as médias móveis, são os indicadores mais poderosos** para prever a tendência do dia seguinte.

4. Modelagem Preditiva: Da Análise Temporal à Engenharia de Features


Após a análise exploratória, a próxima etapa, detalhada no notebook 03_SérieTemporal.ipynb, foi aprofundar a análise sob a ótica de séries temporais e construir o modelo preditivo.

4.1. Decomposição e o Desafio da Estacionariedade

A primeira abordagem foi utilizar a decomposição clássica para entender os componentes da série. Foi aplicada uma decomposição multiplicativa com um período de 248 dias (aproximadamente um ano de pregões), que revelou:

- **Tendência (Trend):** A direção de longo prazo do índice, confirmando os ciclos de alta e baixa.
- **Sazonalidade (Seasonal):** Um padrão repetitivo anual, com o índice mostrando um desempenho mais fraco no meio do ano e recuperação no final.
- **Resíduos (Residuals):** O "ruído" do mercado, com picos de volatilidade que coincidem com eventos não previsíveis como as crises de 2008 e 2020.


Decomposição Multiplicativa do IBOVESPA (Período=248 dias)



Essa forte presença de tendência indica que a série não é estacionária, ou seja, suas propriedades estatísticas (como média e variância) mudam ao longo do tempo. A não-estacionariedade é um problema para modelos estatísticos clássicos como o ARIMA. Para confirmar isso, realizamos o teste de estacionariedade Augmented Dickey-Fuller (ADF):

Série	Teste Estatístico	P-Value	Estacionária (P-Value <= 0.05)
1. Preço Original	-1.1746	0.68442	Não
2. Preço em Log	-1.9117	0.32656	Não
3. Detrended (Log - MA)	-15.0610	9.0045e-28	Sim
4. Detrended e Diferenciada	-19.0284	0.0000e+00	Sim

Os resultados confirmam que apenas após transformações (como a remoção da tendência e a diferenciação) a série se torna estacionária.



4.2. Engenharia de Features: Transformando o Tempo em Informação


Dado que modelos estatísticos como o ARIMA têm dificuldade em lidar com a complexidade e a não-estacionariedade dos dados brutos, a estratégia adotada foi transformar o problema de série temporal em um problema de **classificação supervisionada**. Para isso, criamos um rico conjunto de features (variáveis) a partir dos dados históricos. Essa abordagem permite que modelos de Machine Learning, capturem padrões não-lineares complexos.

A tabela abaixo detalha cada grupo de features criadas e sua justificativa:

Categoria da Feature	Features Criadas	Justificativa e Propósito
Baseadas em Tempo	Ano, Mes, Trimestre, Dia_do_ano, Dia_da_semana	Capturar possíveis padrões sazonais ou cíclicos de longo prazo que a decomposição sugeriu.
Retorno e Variação	log_retorno, Range_HL, Range_OC	Medir a magnitude e a direção dos movimentos diários. O retorno logarítmico normaliza a variação, enquanto os ranges medem a volatilidade intradiária.
Tendência	SMA_21, SMA_14, SMA_63, SMA_252, Dist_SMA_long	Suavizar o ruído e identificar a tendência principal (curto, médio e longo prazo). A distância para a média longa quantifica o quão "esticado" o preço está.
Volatilidade	Volatilidade_21d	Medir a instabilidade recente do mercado. Períodos de alta volatilidade podem indicar reversões ou continuação de tendências.

Volume	Vol_SMA_21, Anomalia_Vol	Capturar a "força" do movimento. Um aumento de preço com alto volume é mais significativo. A anomalia detecta picos de negociação incomuns.
Defasagem (Lags)	Lag_Retorno_D-1 a D-5	Incorporar o "momentum" do mercado. A hipótese é que os retornos dos dias imediatamente anteriores influenciam o retorno de hoje.
Variável Alvo	alvo (1 para alta, 0 para baixa)	Definir o objetivo do modelo: prever se o fechamento do dia seguinte será maior ou menor que o do dia atual.


Após a criação das features, a análise de importância (Feature Importance) com um modelo XGBoost inicial revelou que `log_retorno`, `Máxima`, `Mínima`, `Abertura` e os lags de retorno (`Lag_Retorno_D-1`) foram as variáveis mais influentes.




4.3. Benchmarking e Otimização de Modelos

- Com as features criadas, realizamos uma rodada inicial de testes (benchmark) com diferentes tipos de modelos. Os resultados iniciais não foram satisfatórios:
- **Modelos de Classificação:** XGBoost e SARIMAX alcançaram uma acurácia de apenas **43%**.
- **Modelo de Decomposição:** O Prophet, focado em tendências, obteve **50%** de acurácia, equivalente a um resultado aleatório.

Esses resultados indicam que uma aplicação direta dos modelos não era suficiente. A estratégia então passou a ser a otimização e hibridização. O Prophet foi otimizado, e em seguida, foi criado um **modelo híbrido**, onde o Prophet previa a tendência principal e um segundo modelo XGBoost era treinado para prever os **erros (resíduos)** do Prophet.



Para complementar as métricas numéricas, foi gerado um gráfico que visualiza a performance do modelo em cada um dos 30 dias do conjunto de teste. Esta análise permite uma inspeção qualitativa de quando o modelo acertou e quando errou.



4.4. Resultados Finais e Conclusão do Modelo

- O modelo híbrido (Prophet + XGBoost) demonstrou ser a abordagem mais eficaz, alcançando o resultado final do projeto:

Acurácia Final: 56.67%


- Recall para Alta (1):** 79% (O modelo identificou corretamente 79% de todos os dias que realmente foram de alta).
- Recall para Baixa (0):** 18% (O modelo teve dificuldade em identificar os dias de baixa).

Relatório Final	precision	recall	f1-score	support
Baixa (0)	0.33	0.18	0.24	11
Alta (1)	0.62	0.79	0.70	19
accuracy			0.57	30

5. Conclusão Sobre as Limitações dos Modelos

A jornada de modelagem, desde os testes iniciais até o modelo híbrido final, forneceu um insight crucial sobre por que modelos como ARIMA, Prophet e XGBoost "falharam" em suas formas mais simples. A previsão do mercado financeiro diário é um desafio dominado por **ruído e movimentos não-lineares de alta frequência**, e cada modelo possui limitações inerentes para lidar com esse cenário:

- **ARIMA / SARIMAX:** Estes são modelos lineares que dependem fundamentalmente da estacionariedade dos dados. Embora possamos forçar a estacionariedade com transformações, eles são incapazes de capturar as relações complexas e não-lineares que governam as oscilações diárias do mercado.
- **Prophet:** A grande força do Prophet é decompor e prever tendências claras e sazonalidades (semanais, anuais). Ele é excelente para prever o "esqueleto" da série temporal, mas **não foi projetado para prever o "ruído" diário ou a volatilidade de alta frequência**. Por isso, sua performance em um problema de classificação diária foi medíocre.
- A melhora significativa com o **modelo híbrido** comprova essa tese: ao combinar a força do Prophet (capturar a tendência base) com a força do XGBoost (aprender com os erros e capturar padrões complexos nos resíduos), conseguimos um sistema mais robusto e com poder preditivo superior ao aleatório, validando a abordagem como a mais adequada para este problema.



5. Mudança de Estratégia: Da Previsão Temporal à Classificação

Após a fase de análise e os testes iniciais de modelagem (detalhados no notebook `03_SérieTemporal.ipynb`), um ponto crucial ficou evidente: modelos focados em prever a série temporal, como ARIMA e Prophet, mostraram-se inadequados para capturar as oscilações de alta frequência e o "ruído" do mercado diário. Seus resultados, com acurácias próximas de 50%, indicaram que eles são eficazes para

entender a tendência de longo prazo, mas falham em prever o desafio proposto: a direção do dia seguinte.

Diante dessa constatação, foi realizada uma **mudança estratégica fundamental no projeto**. Em vez de tentar prever o valor futuro do índice, o problema foi reformulado como uma **tarefa de classificação**: "O dia de amanhã será de alta ou de baixa?".

Essa nova abordagem foi implementada no notebook

04_Featured_engineering_e_treinamento_modelos.ipynb e se baseou na seguinte premissa:

O XGBoost é um algoritmo extremamente poderoso e capaz de capturar relações não-lineares complexas, que são a essência dos movimentos diários do mercado. Sua falha inicial não foi do algoritmo em si, mas da informação que lhe foi fornecida. Sozinho, um modelo de classificação não entende a sequência temporal. Portanto, o sucesso desta nova abordagem dependia criticamente da **criação de features robustas que traduzissem a dinâmica do tempo em informações numéricas**.

Dessa forma, o foco do projeto passou a ser a **engenharia de features**, onde o conhecimento adquirido na análise exploratória e temporal foi usado para construir variáveis (lags, médias móveis, volatilidade, etc.) que servissem de insumo para um modelo de classificação robusto. Esta mudança metodológica foi o passo decisivo que permitiu superar as limitações dos modelos puramente temporais e alcançar um resultado com poder preditivo superior.

6. Fase Final: Engenharia de Features e Modelagem Preditiva

Nesta etapa, consolidamos a mudança de estratégia para um problema de classificação. O notebook

04_Featured_engineering_e_treinamento_modelos.ipynb é inteiramente dedicado a enriquecer o dataset com features robustas, selecionar as mais importantes e treinar um modelo de Machine Learning otimizado para a tarefa.

6.1. Engenharia de Features Avançada

O primeiro passo foi expandir o conjunto de features criado anteriormente, adicionando indicadores técnicos clássicos, amplamente utilizados por analistas de mercado. O objetivo era fornecer ao modelo o máximo de contexto possível sobre a dinâmica do mercado. Além das features de tempo, retorno, volume e médias móveis, foram adicionadas:

6.2 Data Leakage (Vazamento de Dados)

Em modelos de previsão para séries temporais, o maior risco é o *data leakage*, que ocorre quando o modelo é treinado com informações que não estariam disponíveis no momento da previsão. Por exemplo, para prever a tendência do dia de amanhã, não podemos usar o preço de fechamento ou o volume de amanhã.

Para evitar isso de forma rigorosa, foi aplicada uma técnica fundamental em **todas** as features calculadas a partir dos dados de mercado (preço e volume): o uso do método `.shift(1)` da biblioteca pandas.

Essa abordagem foi aplicada consistentemente em todas as features de retorno, volume, médias móveis, volatilidade e indicadores técnicos, garantindo que o modelo aprenda a prever a tendência do dia seguinte **exclusivamente com base em informações passadas**, simulando um ambiente de decisão real e tornando a avaliação da performance muito mais confiável.

Dicionário Detalhado das Features Criadas

- A tabela abaixo resume cada feature, sua descrição e a hipótese de mercado por trás de sua criação.

Categoria	Feature	Descrição	Hipótese / Propósito
Tempo	Ano, Mes, Dia_da_semana	Extraí o ano, mês e dia da semana da data.	Capturar padrões sazonais ou semanais (ex: "efeito fim de mês", "efeito segunda-feira").
Retorno	log_retorno	Retorno logarítmico em relação ao fechamento do dia anterior.	Medida padronizada da variação percentual, usada para avaliar a magnitude do movimento do dia.
Variação	Range_HL	Diferença entre o preço máximo e	Mede a volatilidade intradiária . Um

		mínimo do dia anterior.	range alto indica um dia de grande movimentação.
	Range_OC	Diferença entre o preço de fechamento e o de abertura do dia anterior.	Mede a força da tendência intradiária . Um valor muito positivo indica um dia de forte alta.
Volume	Anomalia_Vol	Volume do dia anterior comparado à sua média móvel de 21 dias.	Detecta dias com volume de negociação atípico, que podem sinalizar eventos importantes ou força no movimento.
	Vol_Change_1, Vol_Change_7	Variação percentual do volume em relação a 1 e 7 dias atrás.	Mede a aceleração ou desaceleração recente na atividade de negociação.
Tendência	SMA_21-63, SMA_63-252	Diferença entre médias móveis de curto/médio prazo e médio/longo prazo.	Sinaliza a direção e a força da tendência. Valores positivos indicam tendência de alta.
	Dist_SMA_14	Distância percentual do preço de fechamento anterior em relação à sua média de 14 dias.	Mede o quão "esticado" o preço está em relação à sua média recente, útil para


			estratégias de retorno à média.
Volatilidade	Volatilidade_21d, Volatilidade_252d	Desvio padrão dos retornos logarítmicos dos últimos 21 e 252 dias.	Mede o nível de "agitação" ou risco do mercado em diferentes janelas de tempo.
	Vol_Rel_21	Razão entre a volatilidade de curto e longo prazo.	Indica se o mercado está mais ou menos volátil recentemente em comparação com sua média anual.
	Range_Roll_21	Diferença entre o preço mais alto e o mais baixo dos últimos 21 dias.	Mede a "banda" de negociação do ativo no último mês.
Defasagem	Lag_Retorno_D-{i}	O retorno logarítmico de i dias atrás (de 1 a 5 dias).	Captura o momentum e a autocorrelação de curtíssimo prazo.
	Lag_Ultimo_{lag}	O preço de fechamento de lag dias atrás (1, 3 e 7 dias).	Fornece ao modelo o contexto dos níveis de preço recentes.
Momentum	Momentum_3_7, Momentum_7_14	Diferenças entre médias móveis de retornos de curtíssimo prazo.	Sinaliza aceleração ou desaceleração do movimento recente dos preços.

	RSI	Índice de Força Relativa (janela de 14 dias).	Oscilador que mede a magnitude das mudanças de preço para avaliar condições de sobrecompra (>70) ou sobrevenida (<30).
	MACD	Linha principal do indicador MACD.	Captura a tendência e o momentum do mercado.
	MACD_Signal	Linha de sinal do MACD.	Atua como um "gatilho" para sinais de mudança de tendência, através de seus cruzamentos com a linha MACD.
	MACD_Diff	Diferença entre a linha MACD e a linha de Sinal.	Mede a força da convergência ou divergência entre as linhas, sinalizando aceleração do momentum.
Alvo	alvo	1 se o fechamento do dia seguinte for maior que o atual, 0 caso contrário.	Define o objetivo do modelo: prever a direção do próximo dia. (Não é uma feature, mas a variável a ser prevista).

6.2. Estratégia de Seleção de Features

Com um grande número de features criadas, nem todas seriam úteis; algumas poderiam até adicionar "ruído" e prejudicar a performance do modelo. Para resolver isso, foi adotada uma estratégia de **seleção de features** em duas etapas:

1. **Treinamento de um Modelo Base:** Um primeiro modelo XGBoost foi treinado utilizando **todas** as features criadas.
2. **Análise de Importância (Feature Importance):** Utilizou-se a funcionalidade `feature_importances_` do XGBoost para ranquear as features com base em sua contribuição para a performance do modelo.



Essa análise revelou que as features mais influentes eram consistentemente ligadas ao **comportamento recente do preço e volume**, como os **preços de fechamento de dias anteriores (lags)**, a **distância para as médias móveis** e a **média móvel de volume**. Com base nesse ranking, foram selecionadas as **20 features mais importantes** para compor o dataset final de treinamento.

6.3. Benchmarking de Modelos (Baseline de Performance)

Após a etapa de engenharia de features, o objetivo desta fase é estabelecer um **baseline de performance**. Em vez de apostar em um único algoritmo, foi treinado e avaliado um conjunto diversificado de modelos de classificação para entender quais abordagens se adaptam melhor ao nosso problema de prever a direção do mercado.


A preparação dos dados seguiu as melhores práticas para séries temporais, garantindo que o processo de avaliação seja robusto e livre de vazamento de dados (*data leakage*).

Metodologia

1. **Divisão Cronológica (Treino e Teste):** Para simular um ambiente de previsão realista, o dataset foi dividido cronologicamente:
 - a. **Conjunto de Treino:** Contém todos os dados, exceto os últimos 30 dias. É com este conjunto que os modelos irão aprender os padrões.
 - b. **Conjunto de Teste:** Composto pelos últimos 30 dias de dados. Este conjunto é mantido "intocado" durante o treino e serve para uma avaliação final e imparcial da capacidade de generalização dos modelos.



2. **Seleção de Features (Hipótese Inicial):** Para este primeiro teste, foi selecionado um conjunto inicial de 15 features que representam uma mistura de informações de momentum, tendência, volatilidade e lags. O objetivo era fornecer aos modelos um panorama geral do estado do mercado.
3. **Balanceamento de Classes com SMOTE:** Em muitos problemas de mercado, o número de dias de alta e de baixa pode ser desbalanceado. Para evitar que os modelos se tornem "viciados" em prever a classe majoritária, foi aplicada a técnica **SMOTE (Synthetic Minority Over-sampling Technique)**. O SMOTE cria novas amostras sintéticas da classe minoritária, gerando um conjunto de treino perfeitamente balanceado. É importante notar que esta técnica foi aplicada **apenas no conjunto de treino**, para não contaminar o conjunto de teste.



7.0 . Treinamento e Avaliação dos Modelos

Foi implementado um processo automatizado para treinar e avaliar os seguintes algoritmos de classificação:

- **Logistic Regression:** Um modelo linear, ótimo para estabelecer uma base simples.
- **Random Forest:** Um modelo baseado em árvores de decisão, robusto e eficaz em capturar relações complexas.
- **XGBoost:** Um algoritmo de gradient boosting, conhecido por sua alta performance em competições.
- **LightGBM:** Outra implementação de gradient boosting, otimizada para velocidade e eficiência.

Cada modelo foi treinado com os dados de treino balanceados e avaliado no conjunto de teste.

Análise dos Resultados

Após a execução, os modelos foram ranqueados com base na **Acurácia** e no **F1-Score**, uma métrica que equilibra precisão (precision) e sensibilidade (recall).

Ranking de Performance dos Modelos:

Modelo	Accuracy	F1-Score	ROC-AUC
Random Forest	0.600000	0.603620	0.567130
LightGBM	0.533333	0.524402	0.537037
XGBoost	0.500000	0.483516	0.467593

Logistic Regression	0.400000	0.228571	0.504630
----------------------------	----------	----------	----------

Principais Observações:

- **Vencedor do Baseline:** O **Random Forest** foi o modelo com o melhor desempenho geral, alcançando **60% de acurácia** e um F1-Score de 0.60. Isso significa que, neste teste inicial, ele demonstrou uma capacidade preditiva superior à de um palpite aleatório e se estabeleceu como o modelo mais promissor.
- **Modelos baseados em Árvores (Boosting):** Os modelos de boosting (LightGBM e XGBoost) apresentaram um desempenho modesto, ligeiramente acima de 50%, indicando que, com a configuração e features atuais, eles não conseguiram extrair um sinal tão claro quanto o Random Forest.
- **Falha do Modelo Linear:** A Regressão Logística teve o pior desempenho, com 40% de acurácia. A análise de seu relatório de classificação mostra que ele previu **100% dos casos como "baixa" (classe 0)**, sendo incapaz de identificar um único dia de alta. Isso é um forte indicativo de que a relação entre as features e o alvo é **não-linear** e complexa, justificando o uso de modelos mais robustos como os baseados em árvores de decisão.

7.1. Seleção Sistemática de Features (Feature Selection Loop)

Após o benchmark inicial, o **Random Forest** e o **XGBoost** se mostraram os candidatos mais fortes. A próxima hipótese a ser testada foi: "Será que um subconjunto menor e mais focado de features pode gerar um resultado ainda melhor do que o conjunto inicial de 15 features?" foi implementado um processo de seleção de features por força bruta, onde centenas de combinações de variáveis foram testadas.

Metodologia

1. **Definição das Features Candidatas:** Com base na análise de importância inicial e no conhecimento de mercado, foi selecionado um grupo de 8 features candidatas de alto potencial:
 - a. Lag_Retorno_D-2
 - b. SMA_7
 - c. SMA_14
 - d. Vol_SMA_21
 - e. Dia_da_semana
 - f. RSI
 - g. MACD
 - h. MACD_Signal

2. **Loop de Combinações:** Utilizando a biblioteca `itertools`, foi criado um loop que gerou todas as combinações possíveis dessas 8 features, em grupos de 4, 5, 6 e 7.
3. **Treinamento e Avaliação:** Para cada combinação gerada, um modelo (primeiro Random Forest, depois XGBoost) foi treinado e avaliado no mesmo conjunto de teste de 30 dias, e a acurácia foi registrada. O objetivo era encontrar a combinação que maximizasse a acurácia.

Análise dos Resultados

Esta busca exaustiva revelou um salto significativo de performance em ambos os modelos, superando em muito o baseline inicial.

Resultado do Loop - Random Forest

Métrica	Resultado
Melhor Acurácia Encontrada:	80,00%
Melhor Combinação de Features:	<code>['Lag_Returno_D-2', 'SMA_7', 'SMA_14', 'Vol_SMA_21', 'Dia_da_semana', 'RSI', 'MACD']</code>

Relatório de Classificação do Melhor Modelo (Random Forest)

Classe	Precision	Recall	F1-Score
Baixa (0)	0.88	0.58	0.70
Alta (1)	0.77	0.94	0.85
Acurácia Total	-	-	0.80

Resultado do Loop - XGBoost

Métrica	Resultado
Melhor Acurácia Encontrada:	86,67%

Melhor Combinação de Features:	['Lag_Returno_D-2', 'SMA_7', 'SMA_14', 'Vol_SMA_21', 'Dia_da_semana']
---------------------------------------	---

Relatório de Classificação do Melhor Modelo (XGBoost)

Classe	Precision	Recall	F1-Score
Baixa (0)	0.83	0.83	0.83
Alta (1)	0.89	0.89	0.89
Acurácia Total	-	-	0.87

Principais Observações:

- **Poder Preditivo Oculto:** Como as tabelas demonstram, a busca sistemática revelou que um subconjunto menor de features melhorou drasticamente a performance em comparação com o baseline, validando a importância da etapa de seleção de features.
- **Eficiência do XGBoost:** O XGBoost não apenas alcançou uma acurácia superior (**87%**), como o fez com um conjunto mais enxuto de apenas **5 features**. Isso indica que essa combinação é extremamente eficiente e contém alta informação preditiva, enquanto o Random Forest precisou de 7 features para atingir sua melhor performance (80%).

Conclusão da Etapa

Esta etapa foi crucial para o sucesso do projeto. Ela provou que a seleção cuidadosa de features é mais importante do que a simples quantidade de informações. A combinação de 5 features que levou o XGBoost a 87% de acurácia foi identificada como o conjunto de maior potencial e se tornou a base para a fase final de otimização de hiperparâmetros.

8. Otimização de Hiperparâmetros e Avaliação Final Robusta


Após a seleção do melhor conjunto de features na etapa anterior, o foco passou a ser a otimização dos **hiperparâmetros** do modelo. Hiperparâmetros são as configurações internas do algoritmo (como `max_depth` ou `learning_rate`) que não são aprendidas durante o treino, mas que definem como o modelo irá aprender.

O objetivo desta fase é duplo:

1. Encontrar a combinação de hiperparâmetros que maximiza a performance do modelo.
2. Validar de forma robusta se a alta acurácia encontrada anteriormente não foi um acaso e se o modelo consegue generalizar bem para dados futuros nunca vistos.

8.1. Metodologia: Divisão em Treino, Validação e Teste

Para evitar o *overfitting* (quando o modelo decora os dados de treino e falha em dados novos) e o *look-ahead bias* (quando o modelo é influenciado por informações do futuro), foi adotada uma divisão de dados cronológica em três conjuntos distintos:



- **Conjunto de Treino (2006 a Dez/2024):** O maior e mais antigo conjunto de dados. Utilizado exclusivamente para **treinar** o modelo com cada combinação de hiperparâmetros testada.
- **Conjunto de Validação (Dez/2024 a Fev/2025):** Um período de 30 dias, imediatamente posterior ao treino. Ele funciona como um "simulador do futuro" para **avaliar** qual combinação de hiperparâmetros se sai melhor. A escolha do melhor modelo é baseada em sua performance neste conjunto.
- **Conjunto de Teste (Fev/2025 a Mar/2025):** Os últimos 30 dias de dados. Este conjunto é mantido completamente isolado ("intocado") durante todo o processo de treino e otimização. Ele é usado **apenas uma vez, no final**, para dar a nota final e imparcial do modelo campeão.

Essa abordagem Treino-Validação-Teste é uma prática padrão em Machine Learning para garantir que a performance reportada seja o mais próximo possível da realidade.

8.2. Processo de Otimização (Grid Search)

Com os dados divididos, foi realizado um processo de busca em grade (*Grid Search*) para os dois modelos mais promissores: XGBoost e Random Forest. Para cada um, foram definidas grades de hiperparâmetros a serem testados, e o código iterou sobre todas as combinações possíveis, treinando no conjunto de **treino** e medindo a acurácia no conjunto de **validação** para encontrar a melhor configuração.

8.3. Resultados Finais e Análise Comparativa

Após a otimização, os modelos com os melhores parâmetros encontrados foram retreinados (usando os dados de treino + validação) e, finalmente, avaliados no conjunto de **teste**.

Resumo da Performance:

Modelo	Acurácia (Validação)	Acurácia (Teste Final)
XGBoost	53,33%	80,00%
Random Forest	56,67%	60,00%

Relatório de Classificação Final - XGBoost (Modelo Campeão):

Classe	Precisão	Recall	F1-Score
Baixa (0)	0.71	0.83	0.77
Alta (1)	0.88	0.78	0.82
Acurácia Total	-	-	0.80

Principais Observações:


- Robustez do XGBoost:** A observação mais importante é a capacidade de generalização. Embora o Random Forest tenha tido uma acurácia ligeiramente maior no conjunto de validação (57% vs 53%), sua performance caiu para 60% no teste final. Em contraste, o **XGBoost demonstrou ser muito mais robusto**, saltando para uma acurácia de **80%** nos dados de teste, provando que ele

aprendeu padrões mais gerais e não apenas as particularidades do período de validação.

- **Confirmação do Modelo:** Este resultado final valida a escolha do **XGBoost** como o modelo campeão do projeto, pois ele provou ser o mais confiável na previsão de dados futuros e não vistos.

Conclusão da Etapa


A fase de otimização e validação robusta foi fundamental para confirmar a superioridade do modelo XGBoost. Ao utilizar um conjunto de dados de validação para o ajuste fino e um conjunto de teste intocado para a avaliação final, garantimos que a **acurácia de 80%** é uma medida confiável do poder preditivo do modelo, solidificando-o como a solução final do projeto.



Matriz de Confusão

A matriz de confusão nos dá um detalhamento visual dos acertos e erros do modelo.


- **Análise:** O modelo foi particularmente eficaz em prever os dias de alta (14 acertos de 18), mas também mostrou um bom desempenho nos dias de baixa (10 acertos de 12). O número total de acertos ($10 + 14 = 24$) confirma a acurácia de 80%.



Curva ROC

A Curva ROC avalia a capacidade do modelo de distinguir entre as classes. A Área Sob a Curva (AUC) resume essa capacidade em um único valor.

- **Análise:** A **AUC de 0.73** é considerada um resultado excelente. Isso indica que o modelo tem um alto poder de discriminação, ou seja, ele é muito bom em atribuir uma maior probabilidade de "alta" a um dia que realmente foi de alta, em comparação com um dia de baixa.



9. Avaliação Robusta de Estratégias e Otimização Final

Com dezenas de features criadas, a pergunta é: qual combinação delas produz o melhor modelo? Uma simples divisão treino-teste pode dar um resultado bom ou ruim por mero acaso. Para responder a essa pergunta de forma confiável, foi utilizada uma metodologia de **Validação Cruzada para Séries Temporais (TimeSeriesSplit)**.

Isso nos permite testar diferentes "hipóteses" (conjuntos de features) em múltiplas janelas de tempo, nos dando uma medida de performance (acurácia média) muito mais robusta do que um simples teste único.

9.1. Metodologia: Validação Cruzada para Séries Temporais (TimeSeriesSplit)

Diferente da validação cruzada tradicional, o `TimeSeriesSplit` respeita a ordem cronológica dos dados. Ele cria múltiplas divisões (neste caso, 3 "folds" ou dobras), onde cada uma consiste em:

- **Treinar** o modelo em uma janela de dados passada
- **Testar** o modelo na janela de dados futura imediata

Esse processo é repetido, expandindo a janela de treino, garantindo que o modelo seja sempre testado em dados que ele nunca viu, simulando um ambiente de previsão real. A performance final de uma estratégia não é um único número, mas sim a **média das acurácias** obtidas em cada "fold".

9.2. Etapa 1: Competição de Conjuntos de Features

Nesta etapa, 21 conjuntos de features, representando diferentes estratégias de análise de mercado (baseadas em lags, momentum, volatilidade, etc.), foram colocados para competir. Um modelo XGBoost com parâmetros fixos foi treinado e avaliado para cada conjunto usando o `TimeSeriesSplit`.

Resultado: O conjunto "**16_Vencedores_Combinados**" emergiu como o campeão, obtendo a maior acurácia média.

Ranking dos 5 Melhores Conjuntos de Features:

Conjunto	Acurácia Média	Desvio Padrão
16_Vencedores_Combinados	0.5179	0.0197
14_Cozinha_Redux_A	0.5126	0.0207
21_Smart_Kitchen_Sink	0.5126	0.0147
18_Sinais_de_Reversao	0.5117	0.0164
1_Lags_Simples	0.5111	0.0089

Insight: O resultado de ~52% de acurácia, embora pareça modesto, é significativo. Ele mostra que este conjunto de features possui um **signal preditivo consistente e superior ao aleatório (50%)** através de diferentes janelas de tempo, validado pela baixa variação (desvio padrão).

9.3. Etapa 2: Otimização Final de Hiperparâmetros (GridSearchCV)

Com o conjunto de features campeão definido, o passo seguinte foi realizar um "polimento" final no modelo XGBoost. Utilizou-se a ferramenta `GridSearchCV`, que testa exaustivamente 162 combinações diferentes de hiperparâmetros do modelo, novamente usando o `TimeSeriesSplit` (desta vez com 5 folds para maior robustez).

- **Resultado:** O processo encontrou a combinação ótima de parâmetros que elevou a acurácia média da validação cruzada para **53.01%**.

9.4. Análise dos Resultados e Próximos Passos

O que uma acurácia de 53% realmente significa?

No contexto do mercado financeiro, que é um sistema extremamente complexo e com alto grau de aleatoriedade (eficiente), uma acurácia consistentemente acima de 50% é um resultado muito positivo. Diferente de problemas mais determinísticos (onde se espera >90% de acerto), um pequeno "edge" (vantagem) de 2-3% acima do aleatório, quando aplicado sistematicamente, pode ser a base para uma estratégia lucrativa. O resultado valida que o modelo encontrou um padrão real e repetível nos dados.

Como os resultados poderiam ser mais eficazes?

A performance de ~53% é um excelente ponto de partida, mas poderia ser aprimorada com a inclusão de novas fontes de informação. O modelo atual utiliza apenas dados do próprio índice (endógenos). A performance seria potencialmente mais eficaz se o modelo fosse enriquecido com **dados exógenos (externos)**, tais como:

- **Dados Macroeconômicos:** Taxa de juros (Selic), inflação (IPCA), dados de emprego.
- **Mercados Internacionais:** Variação de índices como o S&P 500.
- **Câmbio e Commodities:** Variação do Dólar e do preço do Petróleo.
- **Análise de Sentimento:** Dados extraídos de notícias do mercado financeiro para medir o "humor" dos investidores.

9.5. Análise de Importância das Features do Modelo Final

Após a otimização completa, foi treinado um modelo final com os melhores parâmetros e o melhor conjunto de features. O gráfico de importância de features revelou quais variáveis foram mais decisivas para as previsões do modelo:

- **Dist_SMA_14 (Distância para a Média de 14 dias):** Foi a feature mais importante, indicando que o modelo aprendeu que a posição "esticada" do preço em relação à sua média recente é um forte indicador para a direção do dia seguinte.
- **Anomalia_Vol (Anomalia de Volume):** A segunda mais importante, confirmando que dias com volume de negociação atípico contêm informação valiosa sobre a força e a convicção do movimento.
- **Dia_da_semana:** Surpreendentemente, manteve-se como uma feature relevante, sugerindo que, em combinação com outras variáveis, ela ajuda o modelo a contextualizar os padrões.

Essa análise final confirma que as decisões do modelo são baseadas em conceitos lógicos e utilizados na análise técnica de mercado.

10. Conclusão e Teoria do Projeto

Este projeto teve como objetivo desenvolver um modelo preditivo para a tendência diária do índice IBOVESPA, superando o desafio imposto pela natureza complexa e ruidosa dos dados financeiros.

A jornada de modelagem, iniciada com abordagens de série temporal clássicas como ARIMA e Prophet, revelou uma limitação fundamental: embora eficazes para capturar tendências de longo prazo, esses modelos falharam em prever as oscilações de alta frequência do dia a dia, resultando em performances equivalentes a um palpite

aleatório. Essa constatação levou a uma **mudança estratégica crucial**, reformulando o problema para uma tarefa de **classificação supervisionada**.

A teoria central validada por este projeto é que o sucesso na previsão de curto prazo do mercado financeiro não reside em prever o valor exato da série, mas sim em **traduzir a dinâmica temporal em um conjunto rico e informativo de features** e utilizar um algoritmo robusto, como o **XGBoost**, para aprender os padrões não-lineares complexos contidos nessas variáveis.

Através de uma metodologia rigorosa, que incluiu um *benchmark* de múltiplos algoritmos, uma seleção sistemática de features e uma otimização de hiperparâmetros com validação cruzada temporal, foi possível desenvolver um modelo final com performance notável. O modelo campeão, utilizando um conjunto enxuto de apenas cinco features, alcançou uma **acurácia final de 80%** e uma **AUC de 0.73** em um conjunto de teste completamente novo, superando com folga a meta de 75% estabelecida.

A análise de importância revelou que o modelo baseia suas decisões principalmente em sinais de **reversão à média de curto prazo (Dist_SMA_14)** e em **anomalias de volume de negociação (Anomalia_Vol)**, confirmando que suas previsões são fundamentadas em lógicas de mercado reconhecidas.

Apesar do sucesso, o modelo possui limitações, operando exclusivamente com dados endógenos (histórico do próprio índice). Futuras iterações poderiam explorar a inclusão de variáveis exógenas — como taxas de juros, câmbio, sentimento de notícias e performance de mercados internacionais — para potencialmente aprimorar ainda mais sua capacidade preditiva.

Em suma, o projeto cumpriu seu objetivo ao entregar um modelo preditivo robusto e validado, que serve como uma ferramenta quantitativa valiosa para complementar a análise e a tomada de decisão no ambiente dinâmico do mercado de capitais.