



FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA

FELIPE DANTAS TAVARES
IZABEL MORAIS DE CARVALHO
JOE ALLAN ZIRN
JORGE MENEZES GUERRA MARTINS
PEDRO AUGUSTO MOREIRA

MACHINE LEARNING AND TIME SERIES

Tech Challenge

São Paulo
2025

LISTA DE ILUSTRAÇÕES

Figura 1 – Amostra do DataFrame IBOVESPA Após a Etapa de Preparação

Figura 2 – Série Temporal de Fechamento Diário do IBOVESPA (2005-2025)

Figura 3 – Boxplot da Distribuição dos Preços de Fechamento do IBOVESPA

Figura 4 – Gráfico de Violino da Densidade dos Preços de Fechamento do IBOVESPA

Figura 5 – Evolução do Volume Diário de Negociação do IBOVESPA (Escala Logarítmica)

Figura 6 – IBOVESPA e Leque de Médias Móveis para Análise de Tendência

Figura 7 – Heatmap da Matriz de Correlação entre as Variáveis do Estudo

Figura 8 – Histograma da Distribuição dos Retornos Diários do IBOVESPA

Figura 9 – Boxplot da Distribuição Anual dos Preços de Fechamento do IBOVESPA

Figura 10 – Análise Comparativa das Distribuições de Preço por Dia da Semana

Figura 11 – Análise Comparativa das Distribuições de Preço por Mês do Ano

Figura 12 – Decomposição Multiplicativa da Série Temporal do IBOVESPA

Figura 13 – Série Temporal do IBOVESPA Após Remoção de Tendência e Diferenciação

Figura 14 – Importância das Features (Feature Importance) Segundo o Modelo XGBoost

Figura 15 – Comparativo de Previsão de Preços (Últimos 30 dias)

Figura 16 – Comparativo de Previsão de Tendência (0/1) dos Modelos Iniciais

Figura 17 – Desempenho Visual da Previsão do Modelo Híbrido vs. Real

Figura 18 – Ranking de Importância das Features Segundo o Modelo XGBoost

Figura 19 – Estratégia de Divisão Cronológica dos Dados (Train/Test Split)

Figura 20 – Ilustração do Processo de Balanceamento com a Técnica SMOTE

Figura 21 – Estratégia de Divisão Cronológica em Treino, Validação e Teste

Figura 22 – Matriz de Confusão do Teste Final (Acurácia de 80%)

Figura 23 – Curva ROC do Teste Final

Figura 24 – Análise Gráfica de Acertos e Erros do Modelo Final na Janela de Teste

LISTA DE TABELAS

Tabela 1 – Resultados do Teste de Estacionariedade Augmented Dickey-Fuller (ADF)

Tabela 2 – Dicionário de Features Desenvolvidas para o Modelo Preditivo

Tabela 3 – Relatório de Classificação Final do Modelo Híbrido

Tabela 4 – Dicionário de Features Desenvolvidas para o Modelo Preditivo

Tabela 5 – Ranking de Performance dos Modelos no Teste de Baseline

Tabela 6 – Resultado da Otimização do Random Forest via Seleção de Features

Tabela 7 – Relatório de Classificação do Melhor Modelo Random Forest

Tabela 8 – Resultado da Otimização do XGBoost via Seleção de Features

Tabela 9 – Relatório de Classificação do Melhor Modelo XGBoost

Tabela 10 – Ranking dos 5 Melhores Conjuntos de Features

Tabela 11 – Comparativo entre XGBoost e Random Forest

Tabela 12 – Relatório de Classificação Final – Modelo Otimizado XGBoost

SUMÁRIO

1 RELATÓRIO TÉCNICO: MODELO PREDITIVO PARA O ÍNDICE IBOVESPA

1.1 Introdução e Objetivo do Projeto

1.2 Preparação e Análise Exploratória dos Dados

1.3 Análise Exploratória dos Dados (EDA)

1.3.1 Análise da Série Temporal Histórica

1.3.2 Análise da Distribuição via Boxplot

1.3.3 Análise de Densidade com Gráfico de Violino

1.3.4 Análise da Série Histórica de Volume

1.3.5 Análise de Tendência com Médias Móveis

1.3.6 Análise de Correlação entre Variáveis

1.3.7 Análise da Distribuição dos Retornos Diários

1.3.8 Evolução Anual da Distribuição de Preços

1.3.9 Investigação de Sazonalidade Semanal ("Efeito Dia da Semana")

1.3.10 Investigação de Sazonalidade Mensal ("Efeito Mês")

1.4 Conclusão da Análise Exploratória

2 MODELAGEM PREDITIVA: ENGENHARIA DE FEATURES E ANÁLISE TEMPORAL

2.1 Decomposição e o Desafio da Estacionariedade

2.2 Engenharia de Features: Da Série Temporal à Classificação Supervisionada

2.3 Benchmarking de Modelos e Desenvolvimento do Modelo Híbrido

2.4 Resultados do Modelo Híbrido

3 DISCUSSÃO CRÍTICA E EVOLUÇÃO DA ESTRATÉGIA

3.1 A Mudança Estratégica: Da Previsão Temporal à Classificação

3.2 Limitações dos Modelos e a Validação da Abordagem Híbrida

4 FASE FINAL: ENGENHARIA DE FEATURES AVANÇADA E MODELAGEM

4.1 Engenharia de Features Avançada e Dicionário de Dados

4.2 Prevenção de Data Leakage: A Metodologia `.shift(1)`

4.3 Seleção de Features via Análise de Importância

4.4 Metodologia de Treinamento e Validação

4.5 Treinamento, Seleção de Features e Otimização

4.5.1 Benchmarking de Modelos para Definição do Baseline

4.5.2 Otimização via Seleção Sistemática de Features (Busca Inicial)

5 OTIMIZAÇÃO ROBUSTA E VALIDAÇÃO FINAL DO MODELO

5.1 Metodologia de Validação: A Abordagem Treino, Validação e Teste

5.2 Metodologia: Validação Cruzada para Séries Temporais (`TimeSeriesSplit`)

5.2.1 Etapa 1: Competição de Conjuntos de Features via Validação Cruzada

5.2.2 Etapa 2: Otimização Final de Hiperparâmetros (`GridSearchCV`)

5.3 Resultados e Análise do Modelo Campeão

5.4 Avaliação Final (Conjunto de Teste Holdout)

6 DISCUSSÃO DOS RESULTADOS E CONCLUSÃO

6.1 Análise dos Resultados e o Significado da Acurácia

6.2 Análise de Importância das Features do Modelo Final

6.3 Conclusão Final e Próximos Passos

REFERÊNCIAS

1. Relatório Técnico: Modelo Preditivo para o Índice IBOVESPA

1.2 Introdução e Objetivo do Projeto

O objetivo central deste projeto é o desenvolvimento de um modelo preditivo para classificar a tendência de fechamento (alta ou baixa) do índice IBOVESPA para o dia subsequente. O modelo foi concebido para servir como insumo em *dashboards* internos, visando auxiliar analistas quantitativos no processo de tomada de decisão.

Para a construção do modelo, utilizou-se a base de dados histórica do IBOVESPA com granularidade diária. A série temporal abrange um período extenso, selecionado para garantir a robustez e a capacidade de generalização do modelo.

1.2 Preparação e Análise Exploratória dos Dados

Esta etapa inicial, documentada no *notebook* “01_exploracao_e_limpeza.ipynb”, consistiu no tratamento e na análise exploratória dos dados brutos. O processo metodológico incluiu:

- Carregamento e Verificação:
 - O conjunto de dados foi importado e inspecionado quanto à sua estrutura, tipos de dados (*dtypes*) e presença de valores ausentes (*missing values*).
- Tratamento e Conversão de Tipos:
 - Colunas de cotação (ex: 'Último', 'Abertura'), originalmente formatadas como *string*, foram convertidas para o tipo numérico (*float*).
 - A coluna de Volume ('Vol.') foi normalizada para um formato numérico unificado, convertendo representações textuais (ex: "B" para bilhões e "M" para milhões) em seus valores numéricos correspondentes.
 - A coluna 'Data' foi convertida para o formato *datetime*, etapa fundamental para a correta indexação e análise da série temporal.
- Ordenação e Exportação:
 - O *DataFrame* foi ordenado cronologicamente. O conjunto de dados tratado foi exportado para um novo arquivo

“01.limpeza_e_padronizacao.csv”, servindo como *input* para as etapas subsequentes.

Figura 1: Amostra do *DataFrame* IBOVESPA Após a Etapa de Preparação.

Out[11]:

	Último	Abertura	Máxima	Mínima	Vol.	Var%
Data						
2005-01-17	24.515	24.924	25.022	24.515	7.506000e+07	-1.64
2005-01-18	24.089	24.515	24.515	24.019	1.794200e+08	-1.74
2005-01-19	24.271	24.091	24.465	24.091	1.131100e+08	0.76
2005-01-20	23.610	24.271	24.271	23.534	1.820600e+08	-2.72
2005-01-21	23.818	23.618	24.006	23.609	9.740000e+07	0.88
...	...	...	...	...	...	...
2025-03-19	132.508	131.476	132.984	131.451	1.220000e+10	0.79
2025-03-20	131.955	132.505	132.713	131.813	1.419000e+10	-0.42
2025-03-21	132.345	132.005	132.588	131.776	1.419000e+10	0.30
2025-03-24	131.321	132.344	132.424	130.992	8.300000e+09	-0.77
2025-03-25	132.068	131.327	133.471	131.325	9.240000e+09	0.57

5000 rows × 6 columns

Fonte: Elaborado pelo autor (2025).


1.3 Análise Exploratória dos Dados (EDA)

Nesta etapa, documentada no *notebook*

“02.Análise_exploratória_dos_dados.ipynb”, foi conduzida uma análise detalhada para identificar padrões e compreender o comportamento da série temporal do IBOVESPA. As principais observações levantadas nesta etapa foram:

1.3.1 Análise da Série Temporal Histórica

Figura 2: Série Temporal de Fechamento Diário do IBOVESPA (2005-2025).



Fonte: Elaborado pelo autor (2025).


A inspeção visual da série temporal (Figura 2) revela que o comportamento do IBOVESPA é marcado por ciclos distintos, influenciados por eventos macroeconômicos externos. O gráfico expõe a volatilidade do ativo, destacando o pico pré-crise de 2008 e sua subsequente retração abrupta.

Após um período de movimento lateralizado (aprox. 2009-2016), o índice apresentou uma nova tendência de alta, interrompida pelo *crash* de março de 2020 (COVID-19). A fase mais recente demonstra uma consolidação de preços, oscilando predominantemente entre 100.000 e 130.000 pontos.

A principal implicação desta análise para a modelagem é a necessidade de um conjunto de dados extenso. O treinamento em um período que abranja múltiplos "regimes" de mercado (ex: alta volatilidade, baixa volatilidade, tendências de alta e baixa) é mandatório para que o modelo preditivo desenvolva capacidade de generalização e evite o viés de performance restrito a um único cenário econômico.

1.3.2 Análise da Distribuição via *Boxplot*

Figura 3: *Boxplot* da Distribuição dos Preços de Fechamento do IBOVESPA.




Fonte: Elaborado pelo autor (2025).

O *boxplot* dos preços de fechamento (Figura 3) revela uma distribuição com forte assimetria positiva (à direita). Essa característica é evidenciada pela mediana, que se encontra visivelmente na metade inferior do intervalo interquartil (IQR), e pela longa cauda superior, que indica uma grande dispersão de valores nas faixas de preço mais altas.

A consequência direta dessa assimetria para o projeto é clara: o modelo será treinado com um volume de dados massivamente maior correspondente a períodos de cotação baixa a média. Isso representa um ponto de atenção, pois os picos históricos, sendo eventos estatisticamente mais raros, podem ser sub-representados no treinamento, o que potencialmente limita a capacidade do modelo de prever com acurácia a ocorrência de novas máximas históricas.

1.3.3 Análise de Densidade com Gráfico de Violino

Figura 4: Gráfico de Violino da Densidade dos Preços de Fechamento do IBOVESPA.



Fonte: Elaborado pelo autor (2025).


A análise de densidade, por meio do gráfico de violino (Figura 4), complementa a análise do *boxplot* e revela a característica mais marcante da distribuição dos preços: ela é bimodal.

O gráfico exibe duas modas (picos de densidade) claras: uma mais proeminente e larga, centrada em aproximadamente 60.000 pontos, e uma segunda, menos densa, em um patamar próximo a 115.000 pontos. Essa bimodalidade indica que o IBOVESPA, em sua história, não se concentrou em torno de uma única média, mas operou em dois regimes de preço principais, onde permaneceu por longos períodos. As áreas mais estreitas do gráfico representam zonas de transição, com menor permanência histórica.

A existência desses dois regimes é uma descoberta crucial. Para o modelo preditivo, isso sugere que uma abordagem simples de regressão a uma média única seria inadequada. O modelo precisará ser robusto o suficiente para identificar o contexto e o regime de mercado vigente, o que reforça a importância da etapa de engenharia de features (*feature engineering*) para capturar essa dinâmica.

1.3.4 Análise da Série Histórica de Volume

Figura 5: Evolução do Volume Diário de Negociação do IBOVESPA (Escala Logarítmica).



Fonte: Elaborado pelo autor (2025).

A análise do volume de negociação em escala logarítmica (Figura 5) revela dinâmicas de mercado que não são aparentes na análise de preços. A característica mais impactante é uma quebra estrutural em 2008, que alterou fundamentalmente a liquidez do IBOVESPA. O volume médio de negociação caiu drasticamente, estabelecendo um novo patamar que perdurou por quase uma década.

Adicionalmente, no final da série histórica, identifica-se um pico de volume extremo e anômalo, um outlier que se desvia de todo o comportamento passado.

Este *outlier* constitui um ponto crítico de atenção pré-modelagem. É mandatório investigar sua natureza: trata-se de um erro na extração dos dados ou de um evento de mercado genuíno? A decisão sobre como tratá-lo é crucial, pois sua magnitude pode distorcer a escala de outras features durante a normalização e impactar negativamente o treinamento do modelo.

1.3.5 Análise de Tendência com Médias Móveis

Figura 6: IBOVESPA e Leque de Médias Móveis para Análise de Tendência.



Fonte: Elaborado pelo autor (2025).


A sobreposição de um leque de médias móveis ao gráfico de preços (Figura 6) é uma técnica eficaz para suavizar a volatilidade e identificar a tendência predominante. Observa-se que em períodos de alta sustentada (*bull markets*), como entre 2016 e 2018, o preço opera consistentemente acima das médias, que atuam como suportes dinâmicos. Em reversões de mercado, como a de 2008, o cruzamento do preço para baixo do leque de médias confirma a nova tendência de baixa e o início de um *bear market*.

O *insight* fundamental desta análise é o vasto potencial das médias móveis para a engenharia de *features*. A relação entre o preço e as médias não é apenas um indicador visual, porque ela pode ser quantificada para alimentar o modelo. Por exemplo, a distância percentual do preço à média de 60 dias pode se tornar uma *feature* de *momentum*, enquanto o estado "preço acima/abaixo da média de 120 dias" pode ser uma *feature* binária de tendência.

Portanto, estes indicadores técnicos serão transformados em variáveis preditivas numéricas, fornecendo ao algoritmo um contexto essencial sobre a força e a direção da tendência do mercado.

1.3.6 Análise de Correlação entre Variáveis

Figura 7: *Heatmap* da Matriz de Correlação entre as Variáveis do Estudo.



Fonte: Elaborado pelo autor (2025).


A matriz de correlação, visualizada através de um *heatmap* (Figura 7), foi gerada para quantificar as relações lineares entre as variáveis. A análise aponta uma multicolinearidade perfeita (correlação de 1.0) entre as variáveis de preço (“Último”, “Abertura”, “Máxima” e “Mínima”), indicando que elas carregam essencialmente a mesma informação.

Adicionalmente, a forte correlação positiva (0.88) entre a variável “Ano” e os preços não representa uma relação causal, mas sim captura a tendência de alta de longo prazo do índice (uma correlação espúria). Em contraste, *features* de calendário (“Mes” e “Dia_da_semana”) não apresentam correlação linear significativa com o preço.

Estas observações fundamentam decisões críticas para a etapa de modelagem. Para evitar instabilidade no modelo, apenas uma variável de preço (“Último”) será utilizada. A variável “Ano” será descartada para impedir que o modelo aprenda uma relação temporal excessivamente simplista. Por fim, a ausência de correlações lineares com datas sugere que o modelo a ser escolhido deve ser capaz de capturar padrões não-lineares complexos.

1.3.7 Análise da Distribuição dos Retornos Diários

Figura 8: Histograma da Distribuição dos Retornos Diários do IBOVESPA.



Fonte: Elaborado pelo autor (2025).

O histograma dos retornos diários (Figura 8) revela a característica estatística mais marcante dos ativos financeiros: uma distribuição leptocúrtica, popularmente conhecida como de "caudas gordas". Embora a vasta maioria dos retornos se concentre em uma faixa estreita em torno de zero, a distribuição apresenta eventos extremos (tanto positivos quanto negativos) que se estendem muito além do que seria previsto por uma distribuição normal.


A existência de caudas gordas é uma informação crucial para a modelagem, pois significa que a probabilidade de ocorrência de um evento de alta volatilidade (*outlier*) é significativamente maior do que o esperado.

A principal implicação disso está na estratégia de treinamento do modelo. Um otimizador que utilize uma função de perda padrão, como o Erro Quadrático Médio (MSE), seria excessivamente penalizado por esses eventos raros, podendo levar a um treinamento instável. Portanto, é prudente considerar o uso de funções de perda

mais robustas a *outliers*, como o Erro Absoluto Médio (MAE) ou a Perda de Huber (*Huber Loss*), que são menos sensíveis a erros de grande magnitude.

1.3.8 Evolução Anual da Distribuição de Preços

Figura 9: *Boxplot* da Distribuição Anual dos Preços de Fechamento do IBOVESPA.




Fonte: Elaborado pelo autor (2025).

A análise da distribuição de preços segmentada por ano (Figura 9) oferece uma visão consolidada da evolução do mercado. Fica evidente a mudança estrutural de patamar do IBOVESPA: até meados de 2018, o índice operava predominantemente abaixo dos 80.000 pontos, enquanto a partir de 2019, consolidou-se em um novo nível, acima dos 100.000 pontos.

Adicionalmente, a altura de cada *boxplot*, que representa o intervalo interquartil (IQR) daquele ano, serve como um *proxy* visual para a volatilidade. Os anos de 2008 e 2020 se destacam com os maiores IQRs, confirmando-os como os períodos de maior instabilidade e dispersão de preços na série histórica. Esta visualização sintetiza diversas descobertas anteriores, como a tendência de longo prazo e a ocorrência de diferentes regimes de volatilidade.

1.3.9 Investigação de Sazonalidade Semanal ("Efeito Dia da Semana")

Figura 10: Análise Comparativa das Distribuições de Preço por Dia da Semana.



Fonte: Elaborado pelo autor (2025).


Uma análise aprofundada foi conduzida para verificar a hipótese de um "efeito dia da semana" nos preços de fechamento. A inspeção visual (Figura 10) através de gráficos de violino e da Função de Distribuição Cumulativa Empírica (ECDF) mostra que as distribuições de preço para cada dia útil da semana são virtualmente idênticas.

A sobreposição perfeita das curvas de ECDF, em particular, é uma forte evidência de que não há dominância estocástica de um dia sobre o outro. Essa conclusão visual é corroborada pela análise de correlação (Seção 1.3.6), que já havia apontado uma correlação linear próxima de zero.

O *insight* final é inequívoco: não há um padrão sazonal semanal estatisticamente relevante nos dados históricos. Consequentemente, a *feature* "dia_da_semana" é considerada de baixo ou nulo poder preditivo e, como ação, será descartada do conjunto final de variáveis para simplificar a modelagem e evitar a introdução de ruído.

1.3.10 Investigação de Sazonalidade Mensal ("Efeito Mês")

Figura 11: Análise Comparativa das Distribuições de Preço por Mês do Ano.



Fonte: Elaborado pelo autor (2025).

Seguindo a mesma metodologia da análise semanal, foi investigada a hipótese de um padrão sazonal mensal. A análise visual (Figura 11), tanto pelos gráficos de violino quanto pela sobreposição das Funções de Distribuição Cumulativa Empírica (ECDF), busca por um "efeito mês" consistente.

Embora note-se uma leve tendência de alta na mediana dos últimos meses do ano, as distribuições gerais permanecem muito semelhantes. O agrupamento denso das curvas no gráfico ECDF é a evidência mais conclusiva de que nenhum mês apresenta uma distribuição de preços estatisticamente distinta dos demais, o que é confirmado pela correlação ínfima (0.0039) já observada.

O *insight* derivado é claro: não existe um "efeito mês" forte e consistente que possa ser explorado como uma variável preditiva confiável. Portanto, para manter o modelo parcimonioso e focado em preditores de maior impacto, a *feature* "Mes" também será descartada do conjunto de treinamento.

1.4 Conclusão da Análise Exploratória

A análise exploratória dos dados históricos do IBOVESPA revelou a natureza complexa e multifacetada do mercado. A jornada do índice não é linear, mas sim

uma série de ciclos, tendências e quebras estruturais, profundamente influenciada por eventos macroeconômicos, como a crise de 2008 e a pandemia de 2020.

Ficou evidente que o IBOVESPA não opera em torno de uma única média, mas em "regimes" de preço e volume distintos, o que valida a necessidade de modelos que se adaptem a diferentes contextos de mercado. A análise de distribuição dos retornos confirmou o fenômeno das "caudas gordas" (leptocurtose): o comportamento mais comum é de pequenas variações, mas a probabilidade de um evento extremo é maior do que o esperado, tornando a gestão de risco um fator crucial. A investigação de padrões sazonais, por sua vez, demonstrou que não há um "efeito calendário" simples, e que variáveis como dia da semana ou mês, isoladamente, não possuem poder preditivo relevante.

Com base nestes *insights*, a hipótese central para a próxima fase é que, apesar da aparente aleatoriedade, existem padrões a serem capturados. A análise sugere que o comportamento recente do preço (*lags*), a dinâmica do volume e as relações com indicadores de tendência (como a distância para as médias móveis) são as fontes mais promissoras de *features* para prever a tendência do dia seguinte. A etapa de Engenharia de *Features* se concentrará em quantificar matematicamente essas relações.

2. Modelagem Preditiva: Engenharia de Features e Análise Temporal


Com base nos *insights* da análise exploratória, esta seção, documentada no *notebook* “03_SérieTemporal.ipynb”, aprofunda a análise sob a ótica de séries temporais e detalha a construção das variáveis preditivas (*features*).

2.1 Decomposição e o Desafio da Estacionariedade

Para validar quantitativamente as observações da EDA sobre tendência e sazonalidade, iniciou-se com a decomposição clássica da série. Foi aplicado um modelo de decomposição multiplicativa com um período de 248 dias (aproximadamente um ano de pregões). A análise, ilustrada na Figura 12, decompõe a série em três componentes:

- Tendência (*Trend*): A direção de longo prazo do índice, confirmando visualmente os ciclos de alta e baixa identificados anteriormente.
- Sazonalidade (*Seasonal*): Revela um padrão repetitivo anual. A análise sugere um desempenho historicamente mais fraco no meio do ano, com uma recuperação gradual no segundo semestre.
- Resíduos (*Residuals*): Representa o ruído ou a volatilidade não explicada pela tendência e sazonalidade. Os picos de resíduos coincidem com eventos imprevisíveis, como as crises de 2008 e 2020.

Figura 12: Decomposição Multiplicativa da Série Temporal do IBOVESPA.



Fonte: Elaborado pelo autor (2025).

A proeminência do componente de tendência (*Trend*) confirma visualmente a não-estacionariedade da série, ou seja, suas propriedades estatísticas (como média e variância) mudam ao longo do tempo. A não-estacionariedade é uma premissa violada por muitos modelos estatísticos clássicos (ex: ARIMA), que exigem que a série tenha média e variância constantes.

Para validar esta observação quantitativamente, aplicou-se o teste *Augmented Dickey-Fuller* (ADF). Os resultados estão sumarizados na Tabela 1.


Tabela 1: Resultados do Teste de Estacionariedade Augmented Dickey-Fuller (ADF).

Série	Teste Estatístico	<i>P-Value</i>	Estacionária (<i>P-Value</i> ≤ 0.05)
1. Preço Original	-1.1746	0.68442	Não
2. Preço em Log	-1.9117	0.32656	Não
3. Detrended (Log - MA)	-15.0610	9.0045e-28	Sim
4. Detrended e Diferenciada	-19.0284	0.0000e+00	Sim

Fonte: Elaborado pelo autor (2025).

O *P-Value* para a série original é significativamente superior a 0.05, falhando em rejeitar a hipótese nula de não-estacionariedade. Apenas após transformações, como a remoção da tendência e a aplicação da diferenciação de primeira ordem, o *P-Value* se torna efetivamente zero, confirmando a estacionariedade da série transformada. O resultado visual dessa transformação é uma série que oscila em torno de uma média constante, como mostra a Figura 13.

Figura 13: Série Temporal do IBOVESPA Após Remoção de Tendência e Diferenciação.



Fonte: Elaborado pelo autor (2025).

2.2 Engenharia de Features: Da Série Temporal à Classificação Supervisionada

A análise da seção anterior demonstrou que a série do IBOVESPA é complexa e não-estacionária, representando um desafio para modelos estatísticos clássicos. Diante disso, a estratégia adotada foi converter o problema de previsão de série temporal em um problema de classificação supervisionada.

Esta abordagem consiste em criar um conjunto rico de variáveis preditivas (*features*) a partir dos dados históricos. O objetivo é que cada linha do *dataset* represente um "retrato" do mercado em um determinado dia (Dia D), e a variável alvo seja a tendência do dia seguinte (Dia D+1). Isso permite a utilização de algoritmos de *Machine Learning* mais robustos, como o XGBoost, capazes de capturar padrões não-lineares complexos que uma análise puramente temporal poderia ignorar.

A Tabela 2 detalha cada grupo de *features* desenvolvidas e sua justificativa técnica.

Tabela 2: Dicionário de Features Desenvolvidas para o Modelo Preditivo.


Categoria da Feature	Features Criadas	Justificativa e Propósito
Baseadas em Tempo	Ano, Mes, Trimestre, Dia_do_ano, Dia_da_semana	Embora a EDA não tenha mostrado correlações lineares, estas features foram incluídas para permitir que o modelo capture possíveis padrões sazonais ou cíclicos não-lineares.
Retorno e Variação	log_retorno, Range_HL, Range_OC	Medir a magnitude e a direção dos movimentos diários. O retorno logarítmico normaliza a variação, enquanto os ranges medem a volatilidade intradiária.
Tendência	SMA_21, SMA_14, SMA_63, SMA_252, Dist_SMA_long	Suavizar o ruído e identificar a tendência principal (curto, médio e longo prazo). A distância para a média longa quantifica o quão "esticado" o preço está.

Volatilidade	Volatilidade_21d	Medir a instabilidade recente do mercado. Períodos de alta volatilidade podem sinalizar reversões ou a continuação de movimentos fortes.
Volume	Vol_SMA_21, Anomalia_Vol	Capturar a "força" do movimento. Um aumento de preço com alto volume serve como confirmação de tendência. A anomalia detecta picos de negociação atípicos.
Defasagem (Lags)	Lag_Retorno_D-1 a D-5	Incorporar o momentum do mercado. A hipótese é que os retornos dos dias imediatamente anteriores contêm informação preditiva para o retorno do dia seguinte (autocorrelação).
Variável Alvo	alvo (1 para alta, 0 para baixa)	Definir o objetivo do modelo: classificar se o preço de fechamento do dia seguinte será maior (1) ou menor/igual (0) ao do dia atual.

Fonte: Elaborado pelo autor (2025).

Após a criação das features, um modelo XGBoost preliminar foi treinado para avaliar a importância relativa de cada variável (Figura 14).

Figura 14: Importância das Features (Feature Importance) Segundo o Modelo XGBoost.



Fonte: Elaborado pelo autor (2025).


A análise de importância revela que as *features* mais influentes estão ligadas ao comportamento mais recente do preço. Variáveis como “*log_retorno*”, os componentes de preço do dia (“*Máxima*”, “*Mínima*”, “*Abertura*”) e os *lags* de retorno (“*Lag_Retorno_D-1*”) dominam o ranking. Este resultado valida a hipótese de que a informação de curto prazo é a mais relevante para a previsão da tendência do dia seguinte, e reforça a eficácia da abordagem de transformar a série temporal em um problema de classificação.

2.3 Benchmarking de Modelos e Desenvolvimento do Modelo Híbrido

Com o conjunto de *features* construído, foi realizada uma rodada de *benchmarking* para avaliar a performance de diferentes abordagens. Os resultados iniciais, no entanto, foram insatisfatórios:

- Modelos de Classificação (XGBoost, SARIMAX): Alcançaram uma acurácia de apenas 43% no conjunto de teste.
- Modelo de Decomposição (Prophet): Obteve 50% de acurácia, um resultado equivalente a uma previsão aleatória.


Figura 15: Comparativo de Previsão de Preços (Últimos 30 dias).



Fonte: Elaborado pelo autor (2025).

Esta performance inicial indicou que uma aplicação direta dos modelos era inadequada. A inspeção visual (Figuras 15 e 16) revela que, embora os modelos tentem seguir a direção geral, eles falham em capturar a volatilidade e as reversões de alta frequência do mercado diário.

Figura 16: Comparativo de Previsão de Tendência (0/1) dos Modelos Iniciais.



Fonte: Elaborado pelo autor (2025).

Diante deste desafio, a estratégia evoluiu para a hibridização. Foi desenvolvido um modelo de dois estágios:

- Estágio 1 (Prophet): Um modelo Prophet otimizado foi treinado para capturar e prever o "esqueleto" da série temporal (a tendência principal e a sazonalidade).
- Estágio 2 (XGBoost): Um segundo modelo XGBoost foi treinado especificamente sobre os erros (resíduos) da previsão do Prophet. A hipótese é que os erros do Prophet não são aleatórios e contêm padrões não-lineares que o XGBoost pode aprender.

A previsão final do modelo híbrido é a soma da previsão de tendência do Prophet com a previsão de resíduos do XGBoost.

2.4 Resultados do Modelo Híbrido

A abordagem híbrida (Prophet + XGBoost) demonstrou ser significativamente mais eficaz, alcançando os seguintes resultados no conjunto de teste:

- **Acurácia Final: 56.67%**

O relatório de classificação detalha a performance:

Tabela 3: Relatório de Classificação Final do Modelo Híbrido.


Métrica	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>
Baixa (0)	0.33	0.18	0.24	11
Alta (1)	0.62	0.79	0.70	19
Accuracy			0.57	30

Fonte: Elaborado pelo autor (2025).

A análise das métricas revela um *insight* importante:

- Recall para Alta (79%): O modelo foi muito eficaz em identificar os dias que, de fato, foram de alta.
- Recall para Baixa (18%): O modelo teve extrema dificuldade em prever os dias de baixa, demonstrando um forte *viés otimista (bullish bias)*. Isso é comum em modelos treinados em longos períodos de tendência de alta, como o histórico do IBOVESPA.

Figura 17: Desempenho Visual da Previsão do Modelo Híbrido vs. Real.



Fonte: Elaborado pelo autor (2025).

3. Discussão Crítica e Evolução da Estratégia

3.1. A Mudança Estratégica: Da Previsão Temporal à Classificação

Após a fase de análise e os testes de *benchmark* (Seção 2.3), um ponto crucial ficou evidente: modelos focados em prever o valor da série temporal, como ARIMA e Prophet, mostraram-se inadequados para o objetivo do projeto. Com acurácias próximas de 50%, ficou claro que eles são eficazes para modelar a tendência de longo prazo (o "esqueleto" da série), mas falham em capturar as oscilações de alta frequência e o "ruído" que definem a direção do dia seguinte.

Diante dessa constatação, foi realizada uma mudança metodológica fundamental: o problema foi reformulado de uma tarefa de regressão temporal para uma tarefa de classificação supervisionada: "O dia de amanhã será de alta ou de baixa?".

Essa nova abordagem, implementada no *notebook* "*04_Featured_engineering_e_treinamento_modelos.ipynb*", partiu da seguinte premissa: um algoritmo como o XGBoost, poderoso em capturar relações não-lineares, falhou inicialmente não por sua capacidade, mas pela falta de informação contextual. A chave para o sucesso seria, portanto, traduzir a dinâmica do tempo em um rico conjunto de variáveis numéricas.

3.2. Limitações dos Modelos e a Validação da Abordagem Híbrida

A performance dos modelos iniciais forneceu *insights* valiosos sobre suas limitações inerentes neste cenário:

- ARIMA / SARIMAX: Sendo modelos lineares, dependem da estacionariedade e são incapazes de modelar as relações complexas e não-lineares que governam as oscilações diárias do mercado.
- Prophet: Sua força é decompor e prever tendências e sazonalidades claras. Ele não foi projetado para prever o ruído estocástico diário, resultando em uma performance medíocre para a classificação da tendência do dia seguinte.

A melhora significativa alcançada com o modelo híbrido (Seção 2.4) comprova essa tese. Ao combinar a força do Prophet (capturar a tendência base) com a do XGBoost (aprender padrões nos resíduos), criamos um sistema mais robusto. Isso validou que a abordagem mais adequada para este problema complexo não era um modelo único, mas a combinação inteligente de diferentes técnicas.

4. Fase Final: Engenharia de Features Avançada e Modelagem

Nesta etapa, consolidamos a estratégia de classificação. O *notebook* “04_Featured_engineering_e_treinamento_modelos.ipynb” é inteiramente dedicado a enriquecer o *dataset* com *features* robustas, selecionar as mais importantes e treinar um modelo de *Machine Learning* otimizado para a tarefa.

4.1. Engenharia de Features Avançada e Dicionário de Dados

A estratégia de classificação foi consolidada pela expansão do conjunto de *features*, adicionando indicadores técnicos clássicos. O objetivo era fornecer ao modelo o máximo de contexto possível sobre a dinâmica de preço, *momentum* e volatilidade do mercado. A Tabela 4 detalha o conjunto final de variáveis desenvolvidas.

Tabela 4: Dicionário de Features Desenvolvidas para o Modelo Preditivo.

Categoria	Feature	Descrição	Hipótese / Propósito
Tempo	Ano, Mes, Dia_da_semana	Extraí o ano, mês e dia da semana da data.	Capturar padrões sazonais ou semanais (ex: "efeito fim de mês").
Retorno	log_retorno	Retorno logarítmico em relação ao fechamento do dia anterior.	Medida padronizada da variação percentual, usada para avaliar a magnitude do movimento do dia.

Variação	Range_HL	Diferença entre o preço máximo e mínimo do dia anterior.	Mede a volatilidade intradiária. Um range alto indica um dia de grande movimentação.
	Range_OC	Diferença entre o preço de fechamento e o de abertura do dia anterior.	Mede a força da tendência intradiária. Um valor muito positivo indica um dia de forte alta.
Volume	Anomalia_Vol	Volume do dia anterior comparado à sua média móvel de 21 dias.	Detecta dias com volume de negociação atípico, que podem sinalizar eventos importantes ou força no movimento.
	Vol_Change_1, Vol_Change_7	Variação percentual do volume em relação a 1 e 7 dias atrás.	Mede a aceleração ou desaceleração recente na atividade de negociação.
Tendência	SMA_21-63, SMA_63-252	Diferença entre médias móveis de curto/médio prazo e médio/longo prazo.	Sinaliza a direção e a força da tendência. Valores positivos indicam tendência de alta.
	Dist_SMA_14	Distância percentual do preço de fechamento anterior em relação à sua média de 14 dias.	Mede o quão "esticado" o preço está em relação à sua média recente, útil para estratégias de retorno à média.
Volatilidade	Volatilidade_21d, Volatilidade_252d	Desvio padrão dos retornos logarítmicos dos últimos 21 e 252 dias.	Mede o nível de "agitação" ou risco do mercado em diferentes janelas de tempo.
	Vol_Rel_21	Razão entre a volatilidade de curto e longo prazo.	Indica se o mercado está mais ou menos volátil recentemente em

			comparação com sua média anual.
	Range_Roll_21	Diferença entre o preço mais alto e o mais baixo dos últimos 21 dias.	Mede a "banda" de negociação do ativo no último mês.
Defasagem	Lag_Retorno_D- {i}	O retorno logarítmico de i dias atrás (de 1 a 5 dias).	Captura o <i>momentum</i> e a autocorrelação de curtíssimo prazo.
	Lag_Ultimo_{lag}	O preço de fechamento de lag dias atrás (1, 3 e 7 dias).	Fornecer ao modelo o contexto dos níveis de preço recentes.
Momentum	Momentum_3_7, Momentum_7_14	Diferenças entre médias móveis de retornos de curtíssimo prazo.	Sinaliza aceleração ou desaceleração do movimento recente dos preços.
	RSI	Índice de Força Relativa (janela de 14 dias).	Oscilador que mede a magnitude das mudanças de preço para avaliar condições de sobrecompra (>70) ou sobrevenda (<30).
	MACD	Linha principal do indicador MACD.	Captura a tendência e o <i>momentum</i> do mercado.
	MACD_Signal	Linha de sinal do MACD.	Atua como um "gatilho" para sinais de mudança de tendência, através de seus cruzamentos com a linha MACD.
	MACD_Diff	Diferença entre a linha MACD e a linha de Sinal.	Mede a força da convergência ou divergência entre as linhas, sinalizando

			aceleração do <i>momentum</i> .
Alvo	alvo	1 se o fechamento do dia seguinte for maior que o atual, 0 caso contrário.	Variável a ser prevista, não é uma <i>feature</i> .

Fonte: Elaborado pelo autor (2025).

4.2. Prevenção de *Data Leakage*: A Metodologia *.shift(1)*


A principal premissa metodológica para garantir a validade do modelo é a prevenção rigorosa de *data leakage* (vazamento de dados). Este fenômeno ocorre quando o modelo é treinado com informações que não estariam disponíveis no momento real da previsão.

Para garantir que cada linha do *dataset* represente fielmente as informações disponíveis antes da ocorrência do evento a ser previsto, todas as *features* calculadas (retornos, médias, volatilidade, etc.) foram defasadas em um período utilizando o método *.shift(1)* da biblioteca *pandas*. Esta disciplina garante que o modelo aprende a prever a tendência do Dia D+1 utilizando exclusivamente informações até o final do Dia D, simulando um ambiente de decisão real e tornando a avaliação de performance fidedigna.

4.3. Seleção de Features via Análise de Importância

A criação de um vasto conjunto de *features* introduz o risco de adicionar ruído e redundância, o que pode degradar a performance do modelo. Para mitigar este risco, adotou-se uma estratégia de seleção baseada na análise de importância (*Feature Importance*) de um modelo XGBoost preliminar.

Figura 18: Ranking de Importância das Features Segundo o Modelo XGBoost.



Fonte: Elaborado pelo autor (2025).

A análise (Figura 18) revelou que as *features* mais influentes estavam ligadas ao comportamento recente do preço (“*Lag_Ultimo_2*”, “*Lag_Ultimo_1*”, “*Máxima*” e “*Mínima*”) e a indicadores de tendência (“*SMA_252*” e “*SMA_21-252*”). Este resultado reforça a hipótese de que a informação de curto prazo é a mais relevante para a previsão da tendência do dia seguinte. Com base neste *ranking*, foram selecionadas as 20 *features* mais importantes para compor o *dataset* final de treinamento.

4.4. Metodologia de Treinamento e Validação

Para estabelecer um baseline de performance e avaliar os modelos de forma robusta, foi definida a seguinte metodologia:

1. Divisão Cronológica (Treino e Teste): Para simular um ambiente de previsão realista, o *dataset* foi dividido cronologicamente, uma prática essencial para dados de séries temporais.
 - Conjunto de Treino: Contém todos os dados, exceto os últimos 30 dias.
 - Conjunto de Teste (*Holdout*): Composto estritamente pelos últimos 30 dias, mantido "intocado" durante o treino para uma avaliação final e imparcial da capacidade de generalização do modelo.


Figura 19: Estratégia de Divisão Cronológica dos Dados (Train/Test Split).



Fonte: DataCamp (2025).

2. Balanceamento de Classes com SMOTE: Para evitar que os modelos se tornem enviesados pela classe majoritária (dias de alta ou baixa), foi aplicada a técnica SMOTE (*Synthetic Minority Over-sampling Technique*). O SMOTE cria amostras sintéticas da classe minoritária, gerando um conjunto de treino balanceado. É crucial notar que esta técnica foi aplicada exclusivamente no conjunto de treino. O conjunto de teste permaneceu em seu estado original para garantir que a avaliação final seja feita sobre a distribuição de dados real.

Figura 20: Ilustração do Processo de Balanceamento com a Técnica SMOTE.



Fonte: Data Knows All (2024).

4.5 Treinamento, Seleção de *Features* e Otimização

Com o conjunto de dados preparado e a metodologia de validação definida, esta seção detalha o processo de treinamento e a otimização sistemática para encontrar o modelo de melhor performance.

4.5.1. *Benchmarking* de Modelos para Definição do Baseline

Para estabelecer um baseline de performance, foi implementado um processo automatizado para treinar e avaliar um conjunto diversificado de algoritmos de classificação. Os modelos escolhidos foram:

- **Logistic Regression:** Um modelo linear, para estabelecer uma base de comparação simples.
- **Random Forest:** Um modelo de ensemble baseado em árvores, robusto a relações complexas.
- **XGBoost e LightGBM:** Algoritmos de *gradient boosting*, conhecidos por sua alta performance.

Cada modelo foi treinado com os dados de treino (balanceados com SMOTE) e avaliado no conjunto de teste.

Tabela 5: Ranking de Performance dos Modelos no Teste de Baseline.

Modelo	Accuracy	F1-Score	ROC-AUC
Random Forest	0.600000	0.603620	0.567130
LightGBM	0.533333	0.524402	0.537037
XGBoost	0.500000	0.483516	0.467593
Logistic Regression	0.400000	0.228571	0.504630

Fonte: Elaborado pelo autor (2025).

Análise dos Resultados do *Baseline*:

- **Modelo de Melhor Desempenho:** O Random Forest emergiu como o modelo mais promissor, alcançando 60% de acurácia. Este resultado, superior ao aleatório, estabeleceu o primeiro baseline de performance e indicou que os modelos baseados em árvores eram os mais adequados para o problema.
- **Colapso do Modelo Linear:** A Regressão Logística teve o pior desempenho, prevendo 100% dos casos como "baixa". Esta falha em identificar um único dia de alta é uma forte evidência de que a relação entre as features e o alvo é fundamentalmente não-linear, validando a escolha por modelos mais complexos.

4.5.2. Otimização via Seleção Sistemática de Features (Busca Inicial)

O benchmark estabeleceu o Random Forest e o XGBoost como os candidatos mais fortes. Como uma primeira etapa de otimização, foi implementada uma busca sistemática (loop) para testar a hipótese de que um subconjunto menor de features poderia gerar um resultado superior.

Metodologia da Busca:

1. **Features Candidatas:** Com base na análise de importância e no conhecimento de mercado, um grupo de 8 *features* de alto potencial foi selecionado.

2. Loop de Combinações: Utilizando a biblioteca *itertools*, foram geradas todas as combinações possíveis dessas 8 *features*, em subconjuntos de 4 a 7 variáveis.
3. Treinamento e Avaliação: Para cada combinação, os modelos Random Forest e XGBoost foram treinados e avaliados, registrando a acurácia para encontrar a combinação ótima.

A busca exaustiva revelou um salto de performance, superando significativamente o baseline.

Tabela 6: Resultado da Otimização do Random Forest via Seleção de Features.

Métrica	Resultado
Melhor Acurácia Encontrada:	80,00%
Melhor Combinação de Features:	['Lag_Retorno_D-2', 'SMA_7', 'SMA_14', 'Vol_SMA_21', 'Dia_da_semana', 'RSI', 'MACD']

Fonte: Elaborado pelo autor (2025).

O relatório de classificação detalhado para este modelo de melhor performance é apresentado na Tabela 7.

Tabela 7: Relatório de Classificação do Melhor Modelo Random Forest.

Classe	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
Baixa (0)	0.88	0.58	0.70
Alta (1)	0.77	0.94	0.85
Acurácia Total	-	-	0.80

Fonte: Elaborado pelo autor (2025).

O mesmo processo foi repetido para o modelo XGBoost, com resultados ainda mais expressivos.

Tabela 8: Resultado da Otimização do XGBoost via Seleção de *Features*.

Métrica	Resultado
Melhor Acurácia Encontrada:	86,67%
Melhor Combinação de Features:	['Lag_Retorno_D-2', 'SMA_7', 'SMA_14', 'Vol_SMA_21', 'Dia_da_semana']

Fonte: Elaborado pelo autor (2025).

O desempenho detalhado do modelo XGBoost otimizado é demonstrado na Tabela 9.

Tabela 9: Relatório de Classificação do Melhor Modelo XGBoost

Classe	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
Baixa (0)	0.83	0.83	0.83
Alta (1)	0.89	0.89	0.89
Acurácia Total	-	-	0.87

Fonte: Elaborado pelo autor (2025).

Conclusão da Etapa de Seleção:

Esta etapa foi crucial para o sucesso do projeto e gerou duas observações principais:

- **Validação da Hipótese:** A busca sistemática provou que um subconjunto menor de *features* melhorou drasticamente a performance, validando a importância da seleção de variáveis.
- **Eficiência do XGBoost:** O XGBoost não apenas alcançou a maior acurácia (86.67%), como o fez com um conjunto mais enxuto de apenas 5 *features*. Isso demonstra que esta combinação é extremamente eficiente e contém alta densidade de informação preditiva.

O conjunto de 5 features que levou o XGBoost a este resultado foi definido como o conjunto ótimo e se tornou a base para a fase final de otimização de hiperparâmetros.


5. Otimização Robusta e Validação Final do Modelo

A etapa anterior revelou um conjunto de features de altíssimo potencial. No entanto, o resultado de 86,67% foi obtido em uma única divisão de treino-teste, o que pode ser suscetível ao acaso. Para garantir que o modelo final fosse verdadeiramente robusto e generalizável, a fase final do projeto adotou metodologias de validação ainda mais rigorosas.

5.1. Metodologia de Validação: A Abordagem Treino, Validação e Teste

Para garantir uma avaliação imparcial e robusta, foi adotada uma divisão de dados cronológica em três conjuntos distintos. Esta é uma prática padrão em *Machine Learning* para séries temporais, projetada para simular um ambiente de previsão real e controlar o risco de o modelo ser influenciado por informações do futuro (*look-ahead bias*).

Figura 21: Estratégia de Divisão Cronológica em Treino, Validação e Teste.



Fonte:

Van Nguyen (2020).

- Conjunto de Treino (2006 a Dez/2024): O maior e mais antigo conjunto de dados. Utilizado exclusivamente para treinar o modelo com cada combinação de hiperparâmetros testada.
- Conjunto de Validação (Dez/2024 a Fev/2025): Um período de 30 dias, imediatamente posterior ao treino. Ele funciona como um "simulador do futuro" para avaliar e selecionar a combinação de hiperparâmetros com melhor desempenho.
- Conjunto de Teste (Fev/2025 a Mar/2025): Os últimos 30 dias de dados. Este conjunto é mantido completamente isolado ("intocado") durante todo o processo de treino e otimização. Ele é usado apenas uma vez, no final, para dar a nota final e imparcial do modelo campeão.

Essa abordagem é a principal defesa do projeto contra o *overfitting*. Ao otimizar o modelo no conjunto de validação e testá-lo em um conjunto de teste completamente diferente, garantimos que a performance final reportada seja uma estimativa confiável de como o modelo se comportará em dados futuros.

5.2. Metodologia: Validação Cruzada para Séries Temporais (TimeSeriesSplit).

Para selecionar o melhor conjunto de *features* e otimizar os hiperparâmetros de forma robusta, foi utilizada a Validação Cruzada para Séries Temporais (TimeSeriesSplit). Diferente da validação cruzada tradicional, esta técnica respeita a ordem cronológica dos dados, criando múltiplas divisões ("*folds*") onde o modelo é sempre treinado em dados passados e testado em dados futuros imediatos.

A performance de uma estratégia não é um único número, mas sim a média das acurácias obtidas em cada fold, fornecendo uma medida muito mais estável do seu poder preditivo real.

5.2.1. Etapa 1: Competição de Conjuntos de Features via Validação Cruzada

Nesta etapa, 21 conjuntos de *features*, representando diferentes hipóteses de mercado, competiram entre si. Um modelo XGBoost com parâmetros fixos foi avaliado para cada conjunto usando o TimeSeriesSplit (3 *folds*).

Tabela 10: Ranking dos 5 Melhores Conjuntos de Features

Conjunto	Acurácia Média	Desvio Padrão
16_Vencedores_Combinados	0.5179	0.0197
14_Cozinha_Redux_A	0.5126	0.0207
21_Smart_Kitchen_Sink	0.5126	0.0147
18_Sinais_de_Reversao	0.5117	0.0164
1_Lags_Simples	0.5111	0.0089

Fonte: Elaborado pelo autor (2025).

O conjunto "16_Vencedores_Combinados" emergiu como o campeão. A acurácia média de ~52%, embora pareça modesta, é um resultado significativo. Ela prova que este conjunto de *features* possui um sinal preditivo consistente e superior ao aleatório (50%) através de diferentes janelas de tempo, validado pela baixa variação (desvio padrão).

5.2.2. Etapa 2: Otimização Final de Hiperparâmetros (GridSearchCV)

Com o conjunto de *features* campeão definido, o passo seguinte foi o "polimento" final do modelo XGBoost. Utilizou-se a ferramenta GridSearchCV, que testou exaustivamente 162 combinações diferentes de hiperparâmetros, novamente usando o TimeSeriesSplit (desta vez com 5 *folds* para maior robustez).

Resultado: O processo encontrou a combinação ótima de parâmetros que elevou a acurácia média da validação cruzada para **53.01%**.

5.3. Resultados e Análise do Modelo Campeão

Após a otimização, os modelos com os melhores parâmetros encontrados foram retreinados (usando os dados de treino + validação) e, finalmente, avaliados no conjunto de teste.

Tabela 11: Comparativo entre XGBoost e Random Forest

Modelo	Acurácia (Validação)	Acurácia (Teste Final)
XGBoost	53,33%	80,00%
Random Forest	56,67%	60,00%

Fonte: Elaborado pelo autor (2025).


Tabela 12: Relatório de Classificação Final – Modelo Otimizado XGBoost

Classe	Precision	Recall	F1-Score
Baixa (0)	0.71	0.83	0.77
Alta (1)	0.88	0.78	0.82
Acurácia Total	-	-	0.80

Fonte: Elaborado pelo autor (2025).

A observação mais importante é a capacidade de generalização do XGBoost. Embora sua performance na validação tenha sido modesta, ela **saltou para 80% no teste final**, provando que o modelo aprendeu padrões gerais e não apenas as particularidades do período de validação, um forte indicativo de que o *overfitting* foi evitado.


Figura 21: Matriz de Confusão do Teste Final (Acurácia de 80%).



Fonte: Elaborado pelo autor (2025).

O detalhamento visual dos acertos e erros mostra que o modelo foi eficaz tanto em prever os dias de baixa (10 acertos de 12) quanto os dias de alta (14 acertos de 18).


Figura 22: Curva ROC do Teste Final.



Fonte: Elaborado pelo autor (2025).

A Área Sob a Curva (AUC) de **0.73** é considerada um bom resultado, indicando que o modelo tem um poder de discriminação significativamente superior a um classificador aleatório.

Figura 23: Análise Gráfica de Acertos e Erros do Modelo Final na Janela de Teste.



Fonte: Elaborado pelo autor (2025).

5.5. Avaliação Final (Conjunto de Teste Holdout)

Após todo o processo de seleção e otimização via validação cruzada, o modelo campeão (melhores *features* + melhores hiperparâmetros) foi finalmente treinado em todos os dados disponíveis até o início do conjunto de teste (período de Fev/2025 a Mar/2025). Este conjunto, mantido completamente isolado ("intocado"), serviu para a avaliação final e imparcial do modelo.

6. Discussão dos Resultados e Conclusão

6.1. Análise dos Resultados e o Significado da Acurácia

A metodologia de validação em duas etapas forneceu dois resultados importantes: uma acurácia média de **53%** na validação cruzada e uma acurácia final de **80%** no conjunto de teste. O que isso significa?

No contexto do mercado financeiro, um sistema complexo e com alto grau de aleatoriedade, uma acurácia consistentemente acima de 50% na validação cruzada, como os **53%** obtidos, é um resultado muito positivo. Diferente de problemas determinísticos, um pequeno "edge" (vantagem) de 2-3% acima do aleatório, quando validado de forma robusta, indica que o modelo encontrou um padrão real e repetível nos dados.

O resultado de **80%** no teste final demonstra que, para o período específico avaliado, a combinação de *features* e parâmetros otimizados foi particularmente eficaz, superando com folga a meta de 75% estabelecida no desafio.

6.2. Análise de Importância das Features do Modelo Final

Após a otimização completa, a análise de importância de *features* do modelo final revelou quais variáveis foram mais decisivas para as previsões:

- **Dist_SMA_14** (Distância para a Média de 14 dias): Foi a *feature* mais importante, indicando que o modelo aprendeu que a posição "esticada" do preço em relação à sua média recente é um forte indicador de reversão para a direção do dia seguinte.

- **Anomalia_Vol** (Anomalia de Volume): A segunda mais importante, confirmando que dias com volume de negociação atípico contêm informação valiosa sobre a força e a convicção do movimento.
- **Dia_da_semana**: Surpreendentemente, manteve-se como uma *feature* relevante, sugerindo que, em combinação com outras variáveis, ela ajuda o modelo a contextualizar os padrões.

Essa análise final confirma que as decisões do modelo são baseadas em conceitos lógicos e utilizados na análise técnica de mercado.

6.3. Conclusão Final e Próximos Passos

Este projeto teve como objetivo desenvolver um modelo preditivo para a tendência diária do índice IBOVESPA. A jornada de modelagem validou a teoria central de que o sucesso na previsão de curto prazo não reside em prever o valor exato da série, mas sim em traduzir a dinâmica temporal em um conjunto rico de *features* e utilizar um algoritmo robusto, como o XGBoost, para aprender os padrões não-lineares.

Através de uma metodologia rigorosa, que incluiu validação cruzada temporal para otimização e um teste final em dados não vistos, foi possível desenvolver um modelo final com performance notável, alcançando **80% de acurácia e 0.73 de AUC**.

Apesar do sucesso, o modelo possui limitações, operando exclusivamente com dados endógenos (histórico do próprio índice). A performance poderia ser potencialmente aprimorada com a inclusão de dados exógenos, tais como:

- **Dados Macroeconômicos**: Taxa de juros (Selic), inflação (IPCA).
- **Mercados Internacionais**: Variação de índices como o S&P 500.
- **Câmbio e Commodities**: Variação do Dólar e do preço do Petróleo.
- **Análise de Sentimento**: Dados extraídos de notícias do mercado financeiro.

Em suma, o projeto cumpriu seu objetivo ao entregar um modelo preditivo robusto e validado, que serve como uma ferramenta quantitativa valiosa para complementar a análise e a tomada de decisão no dinâmico mercado de capitais.

REFERÊNCIAS

DATA CAMP. Model Validation in Python. DataCamp. Disponível em: <https://campus.datacamp.com/courses/model-validation-in-python/validation-basics?ex=1>. Acesso em: 02 out. 2025.

DATA KNOWS ALL. A Guide to Imbalanced Classification. Data Knows All. Disponível em: <https://dataknowsall.com/blog/imbalanced.html>. Acesso em: 09 out. 2025.

AL-NUAIMI, Mustafa. Cross-Validation. Medium. Disponível em: <https://medium.com/@Mustafa77/cross-validation-7c774fb59779>. Acesso em: 12 out. 2025.